

Inferencia de tendencias tempranas en el videojuego League of Legends mediante aprendizaje automático

Asignatura: TFG en Ingeniería de Datos

Autor: Adrián Díaz García

Tutor: Ramón Baldrich Caselles

Fecha: Marzo 2026

1. Introducción y contexto del problema

1.1. Contexto general y la fase de draft

En el ecosistema de los deportes electrónicos, la disponibilidad masiva de datos ha impulsado el desarrollo de modelos predictivos. Sin embargo, en la literatura académica sobre League of Legends (un videojuego multijugador de arena de batalla en línea (MOBA), de alta complejidad táctica y formato de 5 jugadores contra 5), la mayoría de enfoques se concentran en predecir el resultado final de la partida [1] o en diseñar sistemas de recomendación de campeones para maximizar la probabilidad de victoria [2].

En League of Legends, cada uno de los diez jugadores ocupa un rol funcional dentro de la partida: Top, Jungla, Mid, ADC y Support. Antes de comenzar el juego, ambos equipos participan en la fase de draft, un proceso por turnos de selección (picks) y veto (bans) de campeones. Esta fase resulta especialmente relevante porque fija los matchups (enfrentamientos) directos entre campeones de un mismo rol, condiciona las sinergias internas de cada equipo y define parte del contexto estratégico en el que se desarrollarán los primeros minutos de la partida. Además, investigaciones recientes han demostrado empíricamente que la información estática derivada de esta fase contiene señal estadística suficiente para modelar el desarrollo del juego [3], lo que respalda su uso como única entrada predictiva.

A nivel práctico, gran parte de la interpretación del draft sigue dependiendo del conocimiento de los jugadores, quienes suelen asociar determinados campeones o combinaciones con patrones relativamente conocidos (por ejemplo, Supports con mayor propensión a abandonar la línea). Aún así, estas intuiciones rara vez se formalizan mediante variables observables y comparables a escala.

En este contexto, surge una oportunidad desde la Ingeniería de Datos: construir un sistema que, a partir del draft completo y usando datos históricos de partidas de alto nivel, sea capaz de inferir cómo tienden a comportarse roles concretos y composiciones de equipo durante la fase temprana de la partida. El valor aplicado de este enfoque reside en su posible

traducción a un asesor interpretable para jugadores, capaz de ofrecer una lectura previa de cómo suelen jugarse ciertos roles y composiciones dado un contexto concreto.

1.2. El problema a resolver: señal predictiva del draft y comportamiento temprano

El problema central que aborda este proyecto es determinar si la información estática disponible en el draft contiene suficiente señal como para anticipar tendencias tempranas observables durante los primeros minutos de partida.

El trabajo no pretende inferir de forma directa la intención estratégica subjetiva de un jugador ni reconstruir un “plan de partida” completo. En su lugar, plantea una hipótesis más acotada y verificable: que ciertos patrones tempranos observables de comportamiento pueden estar condicionados, al menos parcialmente, por las composiciones aliada y enemiga seleccionadas antes del inicio de la partida.

Para estudiar esta hipótesis, el análisis se concentrará en el early game, entendido como una ventana temporal inicial en la que la influencia del estado de la partida es menor que en fases posteriores. Esta restricción no elimina por completo factores como la ejecución individual, el conocimiento del matchup o la coordinación entre jugadores, pero sí permite estudiar la señal asociada al draft antes de que efectos acumulativos ajenos a éste dominen la partida (como el cansancio, frustración o toma de decisiones muy prolongada).

2. Objetivos y alcance del proyecto

El objetivo principal de este Trabajo de Fin de Grado es desarrollar un sistema basado en aprendizaje automático capaz de inferir tendencias tempranas observables a nivel espacial y de distribución de recursos en partidas de League of Legends, utilizando exclusivamente la información estática disponible en la fase de draft.

Para mitigar el ruido estadístico, el proyecto se centra en modelar los roles determinantes del juego temprano (Jungla y Support) junto con una métrica agregada de equipo.

Esta decisión se debe a dos factores. En primer lugar, la prevención del desbalance de clases y falta de varianza ya que, durante la fase temprana de la partida, los roles de Top, Mid y ADC presentan un comportamiento espacial más bien rígido, ya que su prioridad principal es la ganancia de recursos en sus respectivas posiciones. En segundo lugar, debido al alto coste computacional de procesar trayectorias espaciales masivas desde la API, resulta indispensable para cumplir con la planificación temporal propuesta más adelante.

Para alcanzar el objetivo principal, se establecen los siguientes hitos técnicos:

- Desarrollar un pipeline de extracción y transformación de datos a partir de la API oficial de Riot Games, recolectando métricas espaciales y posicionales durante la ventana temporal del early game (hasta el minuto 14 de partida).
- Definir tres variables mediante descriptores espaciales continuos del timeline temprano, diseñados objetivamente a partir de conocimiento experto del dominio.

- Formular el problema como una clasificación multi-output, en la que cada observación se asocia simultáneamente a tres variables objetivo distintas pero relacionadas.
- Diseñar e implementar un modelo principal basado en aprendizaje multitarea, capaz de explotar una representación compartida del draft y producir una salida binaria probabilística para cada una de las tres tareas.

El alcance del proyecto (núcleo obligatorio) es el siguiente:

- Construcción del dataset.
- Definición operacional de tres etiquetas objetivo a partir de métricas espaciales del early game: dos a nivel de rol (Jungla y Support) y una a nivel de equipo.
- Entrenamiento de un primer modelo funcional de clasificación multi-output y comparación frente a baselines sencillos.
- Construcción de una salida mínima interpretable para los jugadores.

Quedan como posibles ampliaciones el uso de clustering no supervisado como validación, la inclusión de hechizos de invocador u otras variables pre-partida adicionales, una validación temporal más estricta y la aplicación de técnicas avanzadas de calibración de redes neuronales [4] para mejorar la salida probabilística.

3. Tratamiento de datos e Ingeniería de Etiquetas

3.1. Unidad de análisis y la naturaleza de los Matchups

La ingesta de datos se limitará a la región europea (EUW) y a la franja competitiva más alta: el nivel Master+ (que representa los rangos Master, Grandmaster y Challenger), extrayendo la información directamente a través de los endpoints oficiales de la API de Riot Games. Esto se hace con tal de reducir parte del ruido derivado de errores graves de ejecución o desconocimiento del juego de jugadores inexpertos.

La unidad de análisis base es (team_id, match_id). Cada observación contendrá el contexto estático completo del draft, compuesto por los 10 campeones y el lado del mapa de cada equipo. La inclusión de esta última característica es muy importante como variable pre-partida debido a la asimetría estructural que introduce en el early game: primero, condiciona tanto la prioridad estratégica en el propio draft (el equipo del lado azul escoge primero un personaje mientras que el del lado rojo se permite poder reservar la última elección para contrarrestar las opciones enemigas) como las rutas seguras de acceso a los monstruos neutrales tempranos (el mapa no es del todo igual en las zonas objetivo del foso del Dragón y Larvas del Vacío).

3.2. Diseño de etiquetas objetivo

El núcleo de la ingeniería de datos reside en la definición de las etiquetas objetivo. Trabajos anteriores demuestran que es posible extraer patrones latentes de comportamiento [5] y

apoyan el uso de la predicción de trayectorias para interpretar estrategias en MOBAs de forma mucho más rica que, por ejemplo, la simple diferencia de recursos [6], [7].

A partir de estas observaciones se definirán tres índices continuos:

- Rol de Jungla (Presencia en el mapa vs. Orientado a limpieza). Se calculará, para el jungla del equipo, la proporción de frames válidos en líneas o río frente a la proporción de frames en jungla propia.
- Rol de Support (Rotador vs. Anclado a línea). Se medirá la distancia entre las coordenadas del support y las del ADC aliado, junto con la proporción de tiempo que el support pasa fuera de la zona bot-side definida geométricamente.
- Tendencia de Equipo (Superior vs. Inferior). Se construirá una métrica agregada de proporción del terreno a partir de las posiciones del Jungla y Support entre las zonas superior e inferior del mapa.

Una vez calculados estos índices continuos sobre el conjunto de entrenamiento, la binarización se realizará mediante discretización estadística de sus distribuciones observadas. En concreto, las observaciones situadas en los extremos de cada distribución se utilizarán para definir las clases opuestas de cada tarea, mientras que la región central se reservará como espacio neutral o ambiguo. Esta decisión busca maximizar la coherencia semántica de las etiquetas, reducir el ruido de observaciones híbridas y facilitar un entrenamiento supervisado más robusto.

4. Metodología y protocolo experimental

El desarrollo seguirá un ciclo de vida de producto de datos iterativo, fundamentado en un diseño experimental orientado a la reproducibilidad y a la defendibilidad académica del resultado.

4.1. Prevención de Data Leakage

Los modelos predictivos solo utilizarán como entrada información disponible antes del inicio de la partida, es decir, información derivada del draft y de decisiones pre-partida expresamente incluidas en el diseño experimental.

Por el contrario, las etiquetas objetivo se construirán de forma retrospectiva a partir de observaciones realizadas sobre la línea temporal inicial de la partida. Estas observaciones tendrán exclusivamente la función de anotar el comportamiento temprano y no podrán utilizarse, ni directa ni indirectamente, como variables de entrada del modelo.

4.2. Consideración temporal

Dado que League of Legends está sujeto a actualizaciones de balance frecuentes, el proyecto tendrá en cuenta la dimensión temporal del dato durante la evaluación, con el fin de evitar conclusiones excesivamente ligadas a un parche concreto. En esta fase inicial no se fija todavía una manera concreta de validación temporal.

4.3. Modelado principal y baselines

El problema se abordará como una clasificación multi-output, ya que cada observación (`match_id`, `team_id`) se asocia simultáneamente a tres variables objetivo distintas. No obstante, el modelado principal no se limitará a entrenar tres clasificadores independientes empaquetados bajo una misma interfaz, sino que se implementará formalmente mediante aprendizaje multitarea [8]. El objetivo de esta decisión de diseño es explotar la dependencia estadística subyacente entre los tres objetivos, mejorando la generalización del sistema al obligar a la red a construir una representación compartida y robusta del draft.

Para validar la utilidad real del aprendizaje conjunto, se considerarán tres niveles de comparación:

- Baseline trivial. Predicción de la clase mayoritaria para cada tarea.
- Baseline estático y aislado. Modelos simples entrenados exclusivamente a partir del campeón del rol correspondiente, sin incorporar el contexto global del draft.
- Baseline asimétrico del mapa. Una regla heurística o clasificador simple que prediga el comportamiento basándose únicamente en el lado del mapa

Este diseño permitirá responder a una cuestión metodológica central: si el contexto global del draft y el aprendizaje conjunto de tareas relacionadas mejoran de forma medible la capacidad de inferir tendencias tempranas frente a enfoques aislados, ya sean heurísticos o supervisados.

En cuanto a la optimización, cada salida se tratará como una tarea binaria independiente, y el entrenamiento del modelo multitarea se realizará mediante una combinación de pérdidas por tarea. Esto permitirá mantener una evaluación específica por salida sin renunciar a los beneficios potenciales de una representación compartida.

5. Salida funcional esperada

La meta del proyecto será la construcción de un prototipo analítico mínimo capaz de recibir manualmente como entrada 10 campeones (además del resto del contexto del draft) y devolver una salida multi-output compuesta por tres probabilidades de tendencias observadas para el Jungla, Support y como Foco de Equipo. En esta fase, el prototipo puede ser sencillo, por ejemplo mediante ejecución desde terminal, sin requerir una interfaz gráfica.

6. Plan de trabajo y planificación temporal

El proyecto se estructurará en las siguientes fases:

- Fase 1 (Marzo): Revisión bibliográfica, consolidación del problema y de la metodología.
- Fase 2 (Marzo - Abril): Implementación del pipeline desde la API de Riot Games, gestión de rate limits, transformación del dato bruto y almacenamiento del dataset.

- Fase 3 (Abril - Mayo): Análisis exploratorio del timeline, definición y validación de las métricas espaciales continuas para las tres variables objetivo, discretización estadística de sus distribuciones y estudio de prevalencias
- Fase 4 (Mayo): entrenamiento del primer modelo funcional de clasificación multi-output, comparación con baselines sencillos y análisis inicial de resultados.
- Fase 5 (Mayo - Junio): revisión cualitativa de casos, consolidación de resultados, construcción de una demostración funcional mínima y exploración de validación temporal más estricta, calibración avanzada o variables pre-partida adicionales.

Además de las fases técnicas del proyecto, la planificación quedará condicionada por varias entregas obligatorias: Informe de progreso I (19/04), Informe de progreso II (24/05), propuesta de informe final (14/06), propuesta de presentación (21/06) y entrega final del dossier e informe (28/06). Estas fechas actuarán como hitos formales de seguimiento y revisión del trabajo realizado.

7. Bibliografía y fuentes complementarias

- [1] J.-A. Hitar-García, L. Morán-Fernández, and V. Bolón-Canedo, "Machine Learning Methods for Predicting League of Legends Game Outcome," *IEEE Trans. Games*, vol. 15, no. 2, pp. 171–181, 2023.
- [2] H. Lee, D. Hwang, H. Kim, B. Lee, and J. Choo, "DraftRec: Personalized Draft Recommendation for Winning in Multi-Player Online Battle Arena Games," in *Proc. ACM Web Conf. 2022 (WWW '22)*, pp. 3428–3439, 2022.
- [3] L. M. Costa, R. G. Mantovani, F. C. M. Souza, and G. Xexéo, "Feature Analysis to League of Legends Victory Prediction on the Picks and Bans Phase," in *2021 IEEE Conf. Games (CoG)*, pp. 1–5, 2021.
- [4] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On Calibration of Modern Neural Networks," in *Proc. 34th Int. Conf. Mach. Learn. (ICML)*, vol. 70, pp. 1321–1330, 2017.
- [5] A. M. Rama, V. Rodriguez-Fernandez, and D. Camacho, "Finding Behavioural Patterns Among League of Legends Players Through Hidden Markov Models," in *Applications of Evolutionary Computation, Lecture Notes in Computer Science*, vol. 12104, pp. 419–430, 2020.
- [6] G. Wallner, L. Wang, and C. Dormann, "Visualizing the Spatio-Temporal Evolution of Gameplay using Storyline Visualization: A Study with League of Legends," *Proc. ACM Hum.-Comput. Interact.*, vol. 7, CHI PLAY, pp. 1002–1024, 2023.
- [7] Y. Chen, J. Wu, Y. Wu, and D. Liu, "T-Foresight: Interpret moving strategies based on context-aware trajectory prediction," *Visual Informatics*, vol. 9, no. 3, art. 100261, 2025.
- [8] R. Caruana, "Multitask Learning," *Mach. Learn.*, vol. 28, no. 1, pp. 41–75, 1997.